

Modélisation Stochastique et Réseaux Bayésiens

Apprentissage automatique des lois de probabilité conditionnelles

Roland Donat

Université de Bretagne Sud

ENSIBS - Spécialité Cyber Data

<https://roland-donat.github.io/cours-rb/ensibs/>

Plan de la présentation

- 1 Introduction
- 2 Rappels statistiques
- 3 Apprentissage des LPC : Données complètes
- 4 Conclusion
- 5 Bonus : Apprentissage des LPC : Données incomplètes

Objectifs pédagogiques

- Comprendre les problématiques liées à la construction pratique d'un réseau bayésien
- Estimer automatiquement les lois de probabilité conditionnelles (LPC) à partir de données observées sur le phénomène étudié

Plan

- 1 Introduction
- 2 Rappels statistiques
- 3 Apprentissage des LPC : Données complètes
- 4 Conclusion
- 5 Bonus : Apprentissage des LPC : Données incomplètes

Introduction

Objectif

Objectif

- Modéliser un phénomène aléatoire à partir d'un RB
- ⇒ Représenter la loi jointe d'une suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$

Problèmes

- Comment déterminer la structure du RB (i.e. le graphe)?
- Comment estimer les lois de probabilité conditionnelles (LPC) :
 $P(X_d | \text{pa}(X_d)), d = 1, \dots, D?$

Approches envisageables

- Approche par expertise : Utilisation d'avis d'experts et connaissances métiers
- **Approche statistique : Utilisation de bases de données (contenant éventuellement des informations incomplètes)**
- Approche mixte : expertise + bases de données

Introduction

Objectif

Objectif

- Modéliser un phénomène aléatoire à partir d'un RB
- ⇒ Représenter la loi jointe d'une suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$

Problèmes

- Comment déterminer la structure du RB (i.e. le graphe)?
- Comment estimer les lois de probabilité conditionnelles (LPC) : $P(X_d | \text{pa}(X_d)), d = 1, \dots, D$?

Approches envisageables

- Approche par expertise : Utilisation d'avis d'experts et connaissances métiers
- **Approche statistique : Utilisation de bases de données (contenant éventuellement des informations incomplètes)**
- Approche mixte : expertise + bases de données

Introduction

Objectif

Objectif

- Modéliser un phénomène aléatoire à partir d'un RB
- ⇒ Représenter la loi jointe d'une suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$

Problèmes

- Comment déterminer la structure du RB (i.e. le graphe)?
- Comment estimer les lois de probabilité conditionnelles (LPC) : $P(X_d | \text{pa}(X_d))$, $d = 1, \dots, D$?

Approches envisageables


- Approche par expertise : Utilisation d'avis d'experts et connaissances métiers
- **Approche statistique : Utilisation de bases de données (contenant éventuellement des informations incomplètes)**
- Approche mixte : expertise + bases de données

Introduction

Exemple : Pourquoi l'herbe de mon jardin est-elle mouillée?


Introduction

Exemple : Pourquoi l'herbe de mon jardin est-elle mouillée?



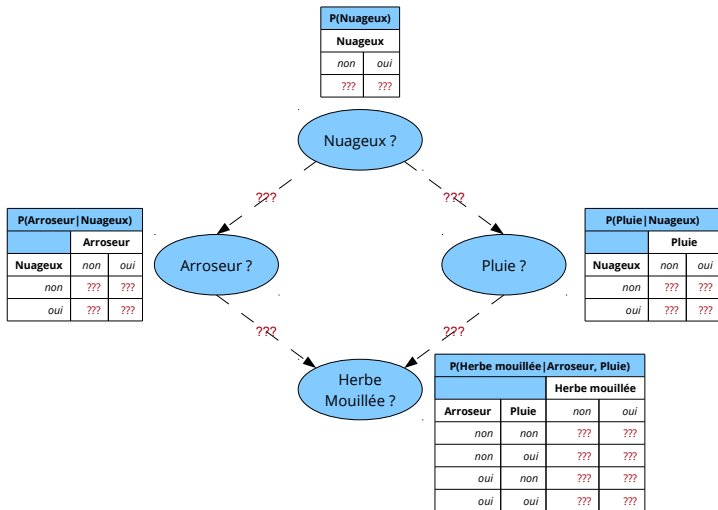
Introduction

Exemple : Pourquoi l'herbe de mon jardin est-elle mouillée?



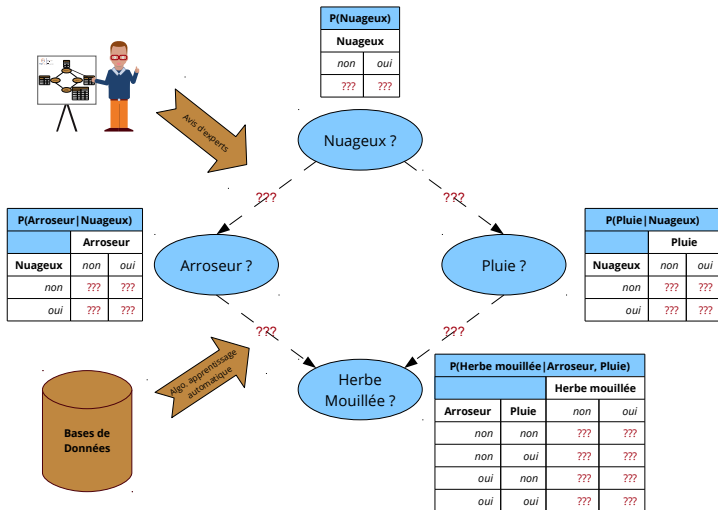
Introduction

Exemple : Pourquoi l'herbe de mon jardin est-elle mouillée?



Introduction

Exemple : Pourquoi l'herbe de mon jardin est-elle mouillée?



Plan

- 1 Introduction
- 2 Rappels statistiques
- 3 Apprentissage des LPC : Données complètes
- 4 Conclusion
- 5 Bonus : Apprentissage des LPC : Données incomplètes

Rappels statistiques

Base de données - Exemple

Date	Éq. dom.	Éq. ext.	FT	HT
2013-08-09	Montpellier	Paris SG	1-1	1-0
2013-08-10	Bordeaux	Monaco	0-2	0-0
2013-08-10	Evian	Sochaux	1-1	1-0
2013-08-10	Lille	Lorient	1-0	1-0
2013-08-10	Lyon	Nice	4-0	1-0
2013-08-10	Nantes	Bastia	2-0	1-0
2013-08-10	Rennes	Reims	2-1	1-1
2013-08-10	Valenciennes	Toulouse	3-0	1-0
2013-08-11	Ajaccio	St Etienne	0-1	0-1
2013-08-11	Guingamp	Marseille	1-3	0-3
2013-08-16	Sochaux	Lyon	1-3	1-2
2013-08-17	Bastia	Valenciennes	2-0	0-0
2013-08-17	Marseille	Evian	2-0	1-0
2013-08-17	Nice	Rennes	2-1	1-1

Rappels statistiques

Base de données - Exemple

Date	Éq. dom.	Éq. ext.	FT	HT
2013-08-09	Montpellier	Paris SG	1-1	1-0
2013-08-10	Bordeaux	Monaco	0-2	0-0
2013-08-10	Evian	Sochaux	1-1	1-0
2013-08-10	Lille	Lorient	1-0	1-0
2013-08-10	Lyon	Nice	4-0	1-0
2013-08-10	Nantes	Bastia	2-0	1-0
2013-08-10	Rennes	Reims	2-1	1-1
2013-08-10	Valenciennes	Toulouse	3-0	1-0
2013-08-11	Ajaccio	St Etienne	0-1	0-1
2013-08-11	Guingamp	Marseille	1-3	0-3
2013-08-16	Sochaux	Lyon	1-3	1-2
2013-08-17	Bastia	Valenciennes	2-0	0-0
2013-08-17	Marseille	Evian	2-0	1-0
2013-08-17	Nice	Rennes	2-1	1-1

Caractéristiques des données

- Nombre de variables : 5
- Valeurs prises par la variable "FT"
- Observation caractérisée par le vecteur (2013-08-10, Lille, Lorient, 1-0, 1-0)

Rappels statistiques

Base de données - Exemple

Date	Éq. dom.	Éq. ext.	FT	HT
2013-08-09	Montpellier	Paris SG	1-1	1-0
2013-08-10	Bordeaux	Monaco	0-2	0-0
2013-08-10	Evian	Sochaux	1-1	1-0
2013-08-10	Lille	Lorient	1-0	1-0
2013-08-10	Lyon	Nice	4-0	1-0
2013-08-10	Nantes	Bastia	2-0	1-0
2013-08-10	Rennes	Reims	2-1	1-1
2013-08-10	Valenciennes	Toulouse	3-0	1-0
2013-08-11	Ajaccio	St Etienne	0-1	0-1
2013-08-11	Guingamp	Marseille	1-3	0-3
2013-08-16	Sochaux	Lyon	1-3	1-2
2013-08-17	Bastia	Valenciennes	2-0	0-0
2013-08-17	Marseille	Evian	2-0	1-0
2013-08-17	Nice	Rennes	2-1	1-1

Caractéristiques des données

- Nombre de variables : 5
- Valeurs prises par la variable "FT"
- Observation caractérisée par le vecteur (2013-08-10, Lille, Lorient, 1-0, 1-0)

Rappels statistiques

Base de données - Exemple

Date	Éq. dom.	Éq. ext.	FT	HT
2013-08-09	Montpellier	Paris SG	1-1	1-0
2013-08-10	Bordeaux	Monaco	0-2	0-0
2013-08-10	Evian	Sochaux	1-1	1-0
2013-08-10	Lille	Lorient	1-0	1-0
2013-08-10	Lyon	Nice	4-0	1-0
2013-08-10	Nantes	Bastia	2-0	1-0
2013-08-10	Rennes	Reims	2-1	1-1
2013-08-10	Valenciennes	Toulouse	3-0	1-0
2013-08-11	Ajaccio	St Etienne	0-1	0-1
2013-08-11	Guingamp	Marseille	1-3	0-3
2013-08-16	Sochaux	Lyon	1-3	1-2
2013-08-17	Bastia	Valenciennes	2-0	0-0
2013-08-17	Marseille	Evian	2-0	1-0
2013-08-17	Nice	Rennes	2-1	1-1

Caractéristiques des données

- Nombre de variables : 5
- Valeurs prises par la variable "FT"
- Observation caractérisée par le vecteur (2013-08-10, Lille, Lorient, 1-0, 1-0)

Rappels statistiques

Base de données - Définition

Définition : Base de données

- Une base de données (BdD), notée \mathcal{D} , est un ensemble de N observations/individus/exemples caractérisés par D variables
- Formellement, une BdD peut se mettre sous la forme d'une matrice :

$$\mathcal{D} = \begin{bmatrix} x_{1,1} & \dots & x_{1,d} & \dots & x_{1,D} \\ \vdots & & \vdots & & \vdots \\ x_{n,1} & \dots & x_{n,d} & \dots & x_{n,D} \\ \vdots & & \vdots & & \vdots \\ x_{N,1} & \dots & x_{N,d} & \dots & x_{N,D} \end{bmatrix}$$

- Le vecteur colonne $\mathbf{x}_{\cdot,d} = (x_{1,d}, \dots, x_{n,d}, \dots, x_{N,d})$ représente toutes les observations de la variable d
- Le vecteur ligne $\mathbf{x}_{n,\cdot} = (x_{n,1}, \dots, x_{n,d}, \dots, x_{n,D})$ représente la n -ème observation de la BdD

Rappels statistiques

Modélisation statistique : objectifs et démarche

Objectifs

- 1 Résumer quantitativement l'information contenue dans une BdD en utilisant un modèle probabiliste
- 2 Exploiter le modèle pour déduire de nouvelles connaissances

Démarche

- Considérer les données comme des réalisations de variables aléatoires (v.a.) associées à une certaine loi jointe
- Formellement, cela signifie que chaque observation $\mathbf{x}_{n,\cdot} = (x_{n,1}, \dots, x_{n,D})$ est supposée être une réalisation d'une suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$ de loi jointe $\mathcal{L}(\theta)$ où θ représente les paramètres de la loi
- Notation : $\mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{L}(\theta)$

Rappels statistiques

Modélisation statistique : objectifs et démarche

Objectifs

- 1 Résumer quantitativement l'information contenue dans une BdD en utilisant un modèle probabiliste
- 2 Exploiter le modèle pour déduire de nouvelles connaissances

Démarche

- Considérer les données comme des réalisations de variables aléatoires (v.a.) associées à une certaine loi jointe
- Formellement, cela signifie que chaque observation $\mathbf{x}_{n,\cdot} = (x_{n,1}, \dots, x_{n,D})$ est supposée être une réalisation d'une suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$ de loi jointe $\mathcal{L}(\boldsymbol{\theta})$ où $\boldsymbol{\theta}$ représente les paramètres de la loi
- Notation : $\mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{L}(\boldsymbol{\theta})$

Rappels statistiques

Modélisation statistique : remarques et exemple

Remarques

- Si les observations dans les données sont indépendants, on parle de données i.i.d. (Indépendantes et Identiquement Distribuées)
- Si les caractéristiques (variables) des observations sont indépendantes, alors chaque variable X_d suit une loi $\mathcal{L}_d(\theta_d)$ (Notation : $X_d \sim \mathcal{L}_d(\theta_d)$)

Modèle gaussien

- Données unidimensionnelles ($D = 1$)
 $\Rightarrow \mathbf{X} = X_1 \sim \mathcal{N}(\mu, \sigma)$
 $\Rightarrow \theta = (\mu, \sigma)$: moyenne et écart-type
- Données multidimensionnelles ($D \geq 1$)
 $\Rightarrow \mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{N}(\mu, \Sigma)$
 $\Rightarrow \theta = (\mu, \Sigma)$: vecteur des moyennes et matrice de variance-covariance

Rappels statistiques

Modélisation statistique : remarques et exemple

Remarques

- Si les observations dans les données sont indépendants, on parle de données i.i.d. (Indépendantes et Identiquement Distribuées)
- Si les caractéristiques (variables) des observations sont indépendantes, alors chaque variable X_d suit une loi $\mathcal{L}_d(\theta_d)$ (Notation : $X_d \sim \mathcal{L}_d(\theta_d)$)

Modèle gaussien

- Données unidimensionnelles ($D = 1$)
 $\Rightarrow \mathbf{X} = X_1 \sim \mathcal{N}(\mu, \sigma)$
 $\Rightarrow \theta = (\mu, \sigma)$: moyenne et écart-type
- Données multidimensionnelles ($D \geq 1$)
 $\Rightarrow \mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$
 $\Rightarrow \theta = (\boldsymbol{\mu}, \boldsymbol{\Sigma})$: vecteur des moyennes et matrice de variance-covariance

Rappels statistiques

Estimation des paramètres d'un modèle

Contexte

- Données : On dispose d'un jeu de données $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ où chaque observation $\mathbf{x}_{n,\cdot}$ est caractérisée par D variables $(x_{n,1}, \dots, x_{n,D})$
- Modélisation : On suppose que \mathcal{D} est une suite de N réalisations i.i.d. du vecteur aléatoire $\mathbf{X} = (X_1, \dots, X_D)$ distribué selon la loi $\mathcal{L}(\boldsymbol{\theta})$
- Problématique : Comment estimer les paramètres $\boldsymbol{\theta}$ à partir des données \mathcal{D} ?

Solution

- Construire un estimateur de $\boldsymbol{\theta}$!
- ⇒ Approche classique : Déterminer l'estimateur du maximum de vraisemblance de $\boldsymbol{\theta}$, souvent noté $\boldsymbol{\theta}^{\text{MV}}$

Rappels statistiques

Estimation des paramètres d'un modèle

Contexte

- Données : On dispose d'un jeu de données $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ où chaque observation $\mathbf{x}_{n,\cdot}$ est caractérisée par D variables $(x_{n,1}, \dots, x_{n,D})$
- Modélisation : On suppose que \mathcal{D} est une suite de N réalisations i.i.d. du vecteur aléatoire $\mathbf{X} = (X_1, \dots, X_D)$ distribué selon la loi $\mathcal{L}(\boldsymbol{\theta})$
- Problématique : Comment estimer les paramètres $\boldsymbol{\theta}$ à partir des données \mathcal{D} ?

Solution

- Construire un estimateur de $\boldsymbol{\theta}$!
- ⇒ Approche classique : Déterminer l'estimateur du maximum de vraisemblance de $\boldsymbol{\theta}$, souvent noté $\boldsymbol{\theta}^{\text{MV}}$

Rappels statistiques

Estimation des paramètres d'un modèle - exemple de données

Données de clientèle bancaire

- Âge : âge de la personne
- Épargne : la personne a-t-elle de l'épargne ?
- Vente livret A : a-t-on réussi à vendre un livret A à cette personne ?

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Rappels statistiques

Définition de la vraisemblance d'un modèle par rapport à une observation

Vraisemblance d'un modèle par rapport à une observation

- Soit $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ un ensemble de données i.i.d. modélisées par les v.a. $\mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{L}(\boldsymbol{\theta})$
- La vraisemblance mesure la plausibilité d'un modèle probabiliste (caractérisé par des paramètres $\boldsymbol{\theta}$) par rapport à l'observation $\mathbf{x}_{n,\cdot} \in \mathcal{D}$
- ⇒ La vraisemblance est notée $L(\boldsymbol{\theta}; \mathbf{x}_{n,\cdot})$
- En pratique le logarithme de la vraisemblance est souvent utilisé, on parle alors de log-vraisemblance $\ell(\boldsymbol{\theta}; \mathbf{x}_{n,\cdot}) = \ln L(\boldsymbol{\theta}; \mathbf{x}_{n,\cdot})$

Interprétation

- une vraisemblance **élevée** signifie que le modèle choisi est **crédible** par rapport à la donnée observée
- une vraisemblance **faible** signifie que le modèle choisi est **peu crédible** par rapport à la donnée observée

Rappels statistiques

Définition de la vraisemblance d'un modèle par rapport à une observation

Vraisemblance d'un modèle par rapport à une observation

- Soit $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ un ensemble de données i.i.d. modélisées par les v.a. $\mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{L}(\boldsymbol{\theta})$
- La vraisemblance mesure la plausibilité d'un modèle probabiliste (caractérisé par des paramètres $\boldsymbol{\theta}$) par rapport à l'observation $\mathbf{x}_{n,\cdot} \in \mathcal{D}$
- ⇒ La vraisemblance est notée $L(\boldsymbol{\theta}; \mathbf{x}_{n,\cdot})$
- En pratique le logarithme de la vraisemblance est souvent utilisé, on parle alors de log-vraisemblance $\ell(\boldsymbol{\theta}; \mathbf{x}_{n,\cdot}) = \ln L(\boldsymbol{\theta}; \mathbf{x}_{n,\cdot})$

Interprétation

- une vraisemblance **élevée** signifie que le modèle choisi est **crédible** par rapport à la donnée observée
- une vraisemblance **faible** signifie que le modèle choisi est **peu crédible** par rapport à la donnée observée

Rappels statistiques

Vraisemblance d'un modèle discret et fini

Vraisemblance d'un modèle discret et fini

- Si les v.a. $\mathbf{X} = (X_1, \dots, X_D)$ sont discrètes et finies, alors la vraisemblance du modèle $P(X_1, \dots, X_D)$ sachant l'observation $\mathbf{x}_{n,\cdot}$ est donnée par :

$$L(P; \mathbf{x}_{n,\cdot}) = P(X_1 = x_{n,1}, \dots, X_D = x_{n,D}), \quad (\text{ici } \theta = P)$$

Exemple

- Observation caractérisée par
 - Âge : [26,59]
 - Épargne : non
 - Vente livret A : échec

⇒ Vraisemblance = 0.12

⇒ Log-vraisemblance $\simeq -2.12$

Rappels statistiques

Vraisemblance d'un modèle discret et fini

Vraisemblance d'un modèle discret et fini

- Si les v.a. $\mathbf{X} = (X_1, \dots, X_D)$ sont discrètes et finies, alors la vraisemblance du modèle $P(X_1, \dots, X_D)$ sachant l'observation $\mathbf{x}_{n,\cdot}$ est donnée par :

$$L(P; \mathbf{x}_{n,\cdot}) = P(X_1 = x_{n,1}, \dots, X_D = x_{n,D}), \quad (\text{ici } \theta = P)$$

Exemple

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	non	échec	0,08
[18,25]	non	succès	0,12
[18,25]	oui	échec	0,0075
[18,25]	oui	succès	0,0425
[26,59]	non	échec	0,12
[26,59]	non	succès	0,08
[26,59]	oui	échec	0,06
[26,59]	oui	succès	0,24
60+	non	échec	0,05625
60+	non	succès	0,00625
60+	oui	échec	0,140625
60+	oui	succès	0,046875

- Observation caractérisée par

- Âge : [26,59]
- Épargne : non
- Vente livret A : échec

⇒ Vraisemblance = 0.12

⇒ Log-vraisemblance $\simeq -2.12$

Rappels statistiques

Vraisemblance d'un modèle discret et fini

Vraisemblance d'un modèle discret et fini

- Si les v.a. $\mathbf{X} = (X_1, \dots, X_D)$ sont discrètes et finies, alors la vraisemblance du modèle $P(X_1, \dots, X_D)$ sachant l'observation $\mathbf{x}_{n,\cdot}$ est donnée par :

$$L(P; \mathbf{x}_{n,\cdot}) = P(X_1 = x_{n,1}, \dots, X_D = x_{n,D}), \quad (\text{ici } \theta = P)$$

Exemple

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	non	échec	0,08
[18,25]	non	succès	0,12
[18,25]	oui	échec	0,0075
[18,25]	oui	succès	0,0425
[26,59]	non	échec	0,12
[26,59]	non	succès	0,08
[26,59]	oui	échec	0,06
[26,59]	oui	succès	0,24
60+	non	échec	0,05625
60+	non	succès	0,00625
60+	oui	échec	0,140625
60+	oui	succès	0,046875

- Observation caractérisée par
 - Âge : [26,59]
 - Épargne : non
 - Vente livret A : échec

⇒ Vraisemblance = 0.12

⇒ Log-vraisemblance $\simeq -2.12$

Rappels statistiques

Vraisemblance d'un modèle discret et fini

Vraisemblance d'un modèle discret et fini

- Si les v.a. $\mathbf{X} = (X_1, \dots, X_D)$ sont discrètes et finies, alors la vraisemblance du modèle $P(X_1, \dots, X_D)$ sachant l'observation $\mathbf{x}_{n,\cdot}$ est donnée par :

$$L(P; \mathbf{x}_{n,\cdot}) = P(X_1 = x_{n,1}, \dots, X_D = x_{n,D}), \quad (\text{ici } \theta = P)$$

Exemple

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	non	échec	0,08
[18,25]	non	succès	0,12
[18,25]	oui	échec	0,0075
[18,25]	oui	succès	0,0425
[26,59]	non	échec	0,12
[26,59]	non	succès	0,08
[26,59]	oui	échec	0,06
[26,59]	oui	succès	0,24
60+	non	échec	0,05625
60+	non	succès	0,00625
60+	oui	échec	0,140625
60+	oui	succès	0,046875

- Observation caractérisée par
 - Âge : [26,59]
 - Épargne : non
 - Vente livret A : échec

⇒ Vraisemblance = 0.12

⇒ Log-vraisemblance $\simeq -2.12$

Rappels statistiques

Vraisemblance d'un modèle par rapport à un jeu de données

Vraisemblance d'un modèle par rapport à un jeu de données

- La vraisemblance d'un modèle (paramétré par θ) par rapport à un jeu de données \mathcal{D} , notée $L(\theta; \mathcal{D})$, correspond à la plausibilité du modèle θ par rapport à l'observation des données \mathcal{D}
- Lorsque les données sont supposées i.i.d., la vraisemblance est définie par

$$L(\theta; \mathcal{D}) = \prod_{n=1}^N L(\theta; \mathbf{x}_{n,\cdot})$$

- Lorsque l'on s'intéresse à un jeu de données, on utilise souvent la log-vraisemblance donnée par

$$\ell(\theta; \mathcal{D}) = \ln L(\theta; \mathcal{D}) = \sum_{n=1}^N \ell(\theta; \mathbf{x}_{n,\cdot})$$

Rappels statistiques

Vraisemblance d'un modèle par rapport à un jeu de données

Interprétation

- La vraisemblance est un indicateur permettant de comparer différents modèles probabilistes compte tenu de données observées
- Dans l'absolu plus la log-vraisemblance d'un modèle par rapport à des \mathcal{D} est élevée, plus le modèle probabiliste considéré est adapté pour représenter le phénomène sous-jacent

Attention

- La vraisemblance décroît avec le nombre de données observées
- ⇒ Il n'est pas pertinent de comparer des vraisemblances obtenues à partir de jeux de données de taille différente
- ⇒ En revanche, il peut être intéressant de comparer des vraisemblances moyennes par donnée observée

Rappels statistiques

Vraisemblance d'un modèle par rapport à jeu de données - Exemple

Loi jointe

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	<i>non</i>	<i>échec</i>	0,08
[18,25]	<i>non</i>	<i>succès</i>	0,12
[18,25]	<i>oui</i>	<i>échec</i>	0,0075
[18,25]	<i>oui</i>	<i>succès</i>	0,0425
[26,59]	<i>non</i>	<i>échec</i>	0,12
[26,59]	<i>non</i>	<i>succès</i>	0,08
[26,59]	<i>oui</i>	<i>échec</i>	0,06
[26,59]	<i>oui</i>	<i>succès</i>	0,24
60+	<i>non</i>	<i>échec</i>	0,05625
60+	<i>non</i>	<i>succès</i>	0,00625
60+	<i>oui</i>	<i>échec</i>	0,140625
60+	<i>oui</i>	<i>succès</i>	0,046875

Données

A : Classe âge	E : Épargne	V : Vente livret A	Vraisemblance	Log-vraisemblance
[26,59]	<i>non</i>	<i>échec</i>		
[18,25]	<i>non</i>	<i>échec</i>		
60+	<i>oui</i>	<i>succès</i>		
Total données				

Rappels statistiques

Vraisemblance d'un modèle par rapport à jeu de données - Exemple

Loi jointe

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	<i>non</i>	<i>échec</i>	0,08
[18,25]	<i>non</i>	<i>succès</i>	0,12
[18,25]	<i>oui</i>	<i>échec</i>	0,0075
[18,25]	<i>oui</i>	<i>succès</i>	0,0425
[26,59]	<i>non</i>	<i>échec</i>	0,12
[26,59]	<i>non</i>	<i>succès</i>	0,08
[26,59]	<i>oui</i>	<i>échec</i>	0,06
[26,59]	<i>oui</i>	<i>succès</i>	0,24
60+	<i>non</i>	<i>échec</i>	0,05625
60+	<i>non</i>	<i>succès</i>	0,00625
60+	<i>oui</i>	<i>échec</i>	0,140625
60+	<i>oui</i>	<i>succès</i>	0,046875

Données

A : Classe âge	E : Épargne	V : Vente livret A	Vraisemblance	Log-vraisemblance
[26,59]	non	échec	0,12	-2.1203
[18,25]	non	échec		
60+	oui	succès		
Total données				

Rappels statistiques

Vraisemblance d'un modèle par rapport à jeu de données - Exemple

Loi jointe

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	non	échec	0,08
[18,25]	non	succès	0,12
[18,25]	oui	échec	0,0075
[18,25]	oui	succès	0,0425
[26,59]	non	échec	0,12
[26,59]	non	succès	0,08
[26,59]	oui	échec	0,06
[26,59]	oui	succès	0,24
60+	non	échec	0,05625
60+	non	succès	0,00625
60+	oui	échec	0,140625
60+	oui	succès	0,046875

Données

A : Classe âge	E : Épargne	V : Vente livret A	Vraisemblance	Log-vraisemblance
[26,59]	non	échec	0,12	-2.1203
[18,25]	non	échec	0,08	-2.5257
60+	oui	succès		
Total données				

Rappels statistiques

Vraisemblance d'un modèle par rapport à jeu de données - Exemple

Loi jointe

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	non	échec	0,08
[18,25]	non	succès	0,12
[18,25]	oui	échec	0,0075
[18,25]	oui	succès	0,0425
[26,59]	non	échec	0,12
[26,59]	non	succès	0,08
[26,59]	oui	échec	0,06
[26,59]	oui	succès	0,24
60+	non	échec	0,05625
60+	non	succès	0,00625
60+	oui	échec	0,140625
60+	oui	succès	0,046875

Données

A : Classe âge	E : Épargne	V : Vente livret A	Vraisemblance	Log-vraisemblance
[26,59]	non	échec	0,12	-2.1203
[18,25]	non	échec	0,08	-2.5257
60+	oui	succès	0,046875	-3.0603
Total données				

Rappels statistiques

Vraisemblance d'un modèle par rapport à jeu de données - Exemple

Loi jointe

P(Âge, Épargne, Vente livret A)			
Âge	Épargne	Vente livret A	Proba
[18,25]	<i>non</i>	<i>échec</i>	0,08
[18,25]	<i>non</i>	<i>succès</i>	0,12
[18,25]	<i>oui</i>	<i>échec</i>	0,0075
[18,25]	<i>oui</i>	<i>succès</i>	0,0425
[26,59]	<i>non</i>	<i>échec</i>	0,12
[26,59]	<i>non</i>	<i>succès</i>	0,08
[26,59]	<i>oui</i>	<i>échec</i>	0,06
[26,59]	<i>oui</i>	<i>succès</i>	0,24
60+	<i>non</i>	<i>échec</i>	0,05625
60+	<i>non</i>	<i>succès</i>	0,00625
60+	<i>oui</i>	<i>échec</i>	0,140625
60+	<i>oui</i>	<i>succès</i>	0,046875

Données

A : Classe âge	E : Épargne	V : Vente livret A	Vraisemblance	Log-vraisemblance
[26,59]	<i>non</i>	<i>échec</i>	0,12	-2.1203
[18,25]	<i>non</i>	<i>échec</i>	0,08	-2.5257
60+	<i>oui</i>	<i>succès</i>	0,046875	-3.0603
Total données			4,5E-4	-7.7063

Rappels statistiques

Estimateur du maximum de vraisemblance

Estimateur du maximum de vraisemblance (Fisher 1922)

- Soit $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ un ensemble de données supposées i.i.d. modélisées par les v.a. $\mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{L}(\boldsymbol{\theta})$
- On dit que $\boldsymbol{\theta}^{\text{MV}}$ est un estimateur du maximum de vraisemblance (EMV) de $\boldsymbol{\theta}$ si $\boldsymbol{\theta}^{\text{MV}}$ maximise la vraisemblance, c-à-d.

$$\boldsymbol{\theta}^{\text{MV}} = \arg \max_{\boldsymbol{\theta}} L(\boldsymbol{\theta}; \mathcal{D})$$

Propriétés des EMV

Les EMV sont :

- Convergents en probabilité vers les paramètres à estimer
- Efficaces, i.e. ils convergent rapidement
- Asymptotiquement normaux, i.e. il est facile de construire des intervalles de confiance sur les estimations obtenues

Rappels statistiques

Estimateur du maximum de vraisemblance

Estimateur du maximum de vraisemblance (Fisher 1922)

- Soit $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ un ensemble de données supposées i.i.d. modélisées par les v.a. $\mathbf{X} = (X_1, \dots, X_D) \sim \mathcal{L}(\boldsymbol{\theta})$
- On dit que $\boldsymbol{\theta}^{\text{MV}}$ est un estimateur du maximum de vraisemblance (EMV) de $\boldsymbol{\theta}$ si $\boldsymbol{\theta}^{\text{MV}}$ maximise la vraisemblance, c-à-d.

$$\boldsymbol{\theta}^{\text{MV}} = \arg \max_{\boldsymbol{\theta}} L(\boldsymbol{\theta}; \mathcal{D})$$

Propriétés des EMV

Les EMV sont :

- Convergents en probabilité vers les paramètres à estimer
- Efficaces, i.e. ils convergent rapidement
- Asymptotiquement normaux, i.e. il est facile de construire des intervalles de confiance sur les estimations obtenues

Plan

- 1 Introduction
- 2 Rappels statistiques
- 3 Apprentissage des LPC : Données complètes
 - Contexte
 - Vraisemblance dans un RB
 - EMV dans un RB
- 4 Conclusion
- 5 Bonus : Apprentissage des LPC : Données incomplètes

Apprentissage des LPC : Données complètes

Contexte

Contexte

- Données : On dispose d'un jeu de données $\mathcal{D} = (\mathbf{x}_{1,\cdot}, \dots, \mathbf{x}_{N,\cdot})$ où chaque observation $\mathbf{x}_{n,\cdot}$ est caractérisée par D variables $(x_{n,1}, \dots, x_{n,D})$
- Modélisation : On suppose que \mathcal{D} est une suite de N réalisations i.i.d. du vecteur aléatoire discret et fini $\mathbf{X} = (X_1, \dots, X_D)$ représenté par un RB \mathcal{M} défini par ses LPC, notées ici $\theta_d = (P(X_d | \text{pa}(X_d)))_{d=1, \dots, D}$
- Le graphe du RB est supposé connu

Apprentissage des LPC : Données complètes

Contexte - Exemple

Données

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec


Apprentissage des LPC : Données complètes

Contexte - Exemple

Données

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Modélisation



Apprentissage des LPC : Données complètes

Vraisemblance dans un RB

Vraisemblance dans un RB

- La vraisemblance du RB $\mathcal{M}(\theta_1, \dots, \theta_D)$ par rapport à une donnée $\mathbf{x}_{n,\cdot} \in \mathcal{D}$ est définie par

$$L(\theta_1, \dots, \theta_D; \mathbf{x}_{n,\cdot}) = \prod_{d=1}^D P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ La vraisemblance du RB $\mathcal{M}(\theta_1, \dots, \theta_D)$ par rapport aux données \mathcal{D} i.i.d. est définie par

$$L(\theta_1, \dots, \theta_D; \mathcal{D}) = \prod_{n=1}^N \prod_{d=1}^D P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ D'où la log-vraisemblance :

$$\ell(\theta_1, \dots, \theta_D; \mathcal{D}) = \sum_{n=1}^N \sum_{d=1}^D \ln P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

Apprentissage des LPC : Données complètes

Vraisemblance dans un RB

Vraisemblance dans un RB

- La vraisemblance du RB $\mathcal{M}(\theta_1, \dots, \theta_D)$ par rapport à une donnée $\mathbf{x}_{n,\cdot} \in \mathcal{D}$ est définie par

$$L(\theta_1, \dots, \theta_D; \mathbf{x}_{n,\cdot}) = \prod_{d=1}^D P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ La vraisemblance du RB $\mathcal{M}(\theta_1, \dots, \theta_D)$ par rapport aux données \mathcal{D} i.i.d. est définie par

$$L(\theta_1, \dots, \theta_D; \mathcal{D}) = \prod_{n=1}^N \prod_{d=1}^D P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ D'où la log-vraisemblance :

$$\ell(\theta_1, \dots, \theta_D; \mathcal{D}) = \sum_{n=1}^N \sum_{d=1}^D \ln P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

Apprentissage des LPC : Données complètes

Vraisemblance dans un RB

Vraisemblance dans un RB

- La vraisemblance du RB $\mathcal{M}(\theta_1, \dots, \theta_D)$ par rapport à une donnée $\mathbf{x}_{n,\cdot} \in \mathcal{D}$ est définie par

$$L(\theta_1, \dots, \theta_D; \mathbf{x}_{n,\cdot}) = \prod_{d=1}^D P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ La vraisemblance du RB $\mathcal{M}(\theta_1, \dots, \theta_D)$ par rapport aux données \mathcal{D} i.i.d. est définie par

$$L(\theta_1, \dots, \theta_D; \mathcal{D}) = \prod_{n=1}^N \prod_{d=1}^D P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ D'où la log-vraisemblance :

$$\ell(\theta_1, \dots, \theta_D; \mathcal{D}) = \sum_{n=1}^N \sum_{d=1}^D \ln P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

$$\wedge P^{MV}(\text{Âge})$$

Âge		
[18,25]	[26,59]	60+

$$\wedge P^{MV}(\text{Épargne})$$

Épargne	
non	oui



$$\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non		
[18,25]	oui		
[26,59]	non		
[26,59]	oui		
60+	non		
60+	oui		

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

$$\wedge P^{MV}(\text{Âge})$$

Âge		
[18,25]	[26,59]	60+
3/14	7/14	4/14

$$\wedge P^{MV}(\text{Épargne})$$

Épargne	
non	oui



$$\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non		
[18,25]	oui		
[26,59]	non		
[26,59]	oui		
60+	non		
60+	oui		

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

 $\wedge P^{MV}(\text{Âge})$

Âge		
[18,25]	[26,59]	60+
3/14	7/14	4/14

 $\wedge P^{MV}(\text{Épargne})$

Épargne	
non	oui
9/14	5/14


 $\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non		
[18,25]	oui		
[26,59]	non		
[26,59]	oui		
60+	non		
60+	oui		

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

 $\wedge P^{MV}(\text{Âge})$

Âge		
[18,25]	[26,59]	60+
3/14	7/14	4/14

 $\wedge P^{MV}(\text{Épargne})$

Épargne	
non	oui
9/14	5/14


 $\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non	1/2	1/2
[18,25]	oui		
[26,59]	non		
[26,59]	oui		
60+	non		
60+	oui		

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

 $\wedge P^{MV}(\text{Âge})$

Âge		
[18,25]	[26,59]	60+
3/14	7/14	4/14

 $\wedge P^{MV}(\text{Épargne})$

Épargne	
non	oui
9/14	5/14


 $\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non	1/2	1/2
[18,25]	oui	0/1	1/1
[26,59]	non		
[26,59]	oui		
60+	non		
60+	oui		

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

 $\wedge P^{MV}(\text{Âge})$

Âge		
[18,25]	[26,59]	60+
3/14	7/14	4/14

 $\wedge P^{MV}(\text{Épargne})$

Épargne	
non	oui
9/14	5/14


 $\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non	1/2	1/2
[18,25]	oui	0/1	1/1
[26,59]	non	4/5	1/5
[26,59]	oui	1/2	1/2
60+	non	2/2	0/2
60+	oui	1/2	1/2

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes


Maximum de vraisemblance dans un RB - Exemple

 $\wedge P^{MV}(\text{Âge})$

Âge		
[18,25]	[26,59]	60+
3/14	7/14	4/14

 $\wedge P^{MV}(\text{Épargne})$

Épargne	
non	oui
9/14	5/14


 $\wedge P^{MV}(\text{Vente} | \text{Âge}, \text{Épargne})$

		Vente	
Âge	Épargne	échec	succès
[18,25]	non	1/2	1/2
[18,25]	oui	0/1	1/1
[26,59]	non	4/5	1/5
[26,59]	oui	1/2	1/2
60+	non	2/2	0/2
60+	oui	1/2	1/2

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Apprentissage des LPC : Données complètes

Maximum de vraisemblance dans un RB

Estimateurs du maximum de vraisemblance

- On cherche les estimateurs du maximum de vraisemblance (EMV) des LPC $\theta_1^{\text{MV}}, \dots, \theta_D^{\text{MV}}$ vérifiant :

$$(\theta_1^{\text{MV}}, \dots, \theta_D^{\text{MV}}) = \arg \max_{\theta_1, \dots, \theta_D} \sum_{n=1}^N \sum_{d=1}^D \ln P(X_d = x_{n,d} | \text{pa}(X_d) = \text{pa}(x_{n,d}))$$

- ⇒ Les estimations du maximum de vraisemblance pour chaque LPC ont pour expression :

$$\hat{\theta}^{\text{MV}}(X_d = x_{d,k} | \text{pa}(X_d) = \mathbf{x}'_{d,j}) = \hat{\theta}_{d,j,k}^{\text{MV}} = \frac{N_{d,j,k}}{\sum_{k=1} N_{d,j,k}}$$

- $x_{d,k}$: k -ème valeur possible pour la v.a. X_d
- $\mathbf{x}'_{d,j}$: j -ème configuration de valeurs possibles pour les parents de la v.a. X_d
- $N_{d,j,k}$: Nombre d'occurrences de l'événement $\{X_d = x_{d,k} \text{ et } \text{pa}(X_d) = \mathbf{x}'_{d,j}\}$ dans les données \mathcal{D}

Plan

- 1 Introduction
- 2 Rappels statistiques
- 3 Apprentissage des LPC : Données complètes
- 4 Conclusion
- 5 Bonus : Apprentissage des LPC : Données incomplètes

Conclusion

Compétences acquises

- Rappels généraux sur l'apprentissage statistique
- Formalisation du problème d'apprentissage des LPC du point de vue statistique
- Mise en oeuvre de la méthode du maximum de vraisemblance pour estimer les LPC d'un RB

Pour aller plus loin

- Apprentissage des LPC dans le cas de données incomplètes
- Apprentissage automatique de la structure d'un RB

Plan

- 1 Introduction
- 2 Rappels statistiques
- 3 Apprentissage des LPC : Données complètes
- 4 Conclusion
- 5 **Bonus : Apprentissage des LPC : Données incomplètes**
 - Représentation disjonctive des données
 - Types de données incomplètes
 - Hypothèses autour des données manquantes
 - Algorithme EM
 - Algorithme EM dans les RB

Apprentissage des LPC : Données incomplètes

Représentation disjonctive des données

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Représentation classique

- Les observations de chaque variable sont données explicitement
- ⇒ Représentation intuitive mais peu adaptée aux traitements des données incomplètes

Apprentissage des LPC : Données incomplètes

Représentation disjonctive des données

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	1	0	1	0
0	1	0	1	0	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
0	0	1	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	1	0

Représentation disjonctive

- Chaque variable X possédant K modalités est décomposée en K sous-variables binaires où la modalité prise est associée à la valeur 1
- ⇒ Représentation plus complexe mais adaptée aux traitements des différents types de données incomplètes

Apprentissage des LPC : Données incomplètes

Types de données incomplètes

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
60+	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Types de données incomplètes

- 1 Données manquantes
- 2 Données partiellement observées (généralisation cas 1)
- 3 Données partiellement observées pondérées (généralisation cas 1-2)

Apprentissage des LPC : Données incomplètes

Types de données incomplètes

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
?	non	échec
[26,59]	non	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
?	non	échec
[26,59]	?	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	échec

Types de données incomplètes

- 1 Données manquantes
- 2 Données partiellement observées (généralisation cas 1)
- 3 Données partiellement observées pondérées (généralisation cas 1-2)

Apprentissage des LPC : Données incomplètes

Types de données incomplètes

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
?	?	?	1	0	1	0
0	1	0	1	0	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
?	?	?	1	0	1	0
0	1	0	?	?	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	1	0

Types de données incomplètes

- 1 Données manquantes
- 2 Données partiellement observées (généralisation cas 1)
- 3 Données partiellement observées pondérées (généralisation cas 1-2)

Apprentissage des LPC : Données incomplètes

Types de données incomplètes

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
?	?	0	1	0	1	0
0	1	0	1	0	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
0	?	?	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	1	0

Types de données incomplètes

- Données manquantes
- Données partiellement observées (généralisation cas 1)
- Données partiellement observées pondérées (généralisation cas 1-2)

Apprentissage des LPC : Données incomplètes

Types de données incomplètes

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	1	0	1	0	1	0
0	1	0	1	0	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
0	1/3	2/3	1	0	1	0
0	1	0	1	1	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	1	0

Types de données incomplètes

- Données manquantes
- Données partiellement observées (généralisation cas 1)
- Données partiellement observées pondérées (généralisation cas 1-2)

Apprentissage des LPC : Données incomplètes

Types de données incomplètes (Rubin 1976)

Hypothèse MCAR : *Missing Completely At Random*

- La perte de données est issue d'un phénomène aléatoire indépendant des variables observées
- ⇒ Filtrage des données manquantes pour l'estimation des paramètres

Hypothèse MAR : *Missing At Random*

- Les variables ayant des observations manquantes dépendent de variables observées
- ⇒ Estimer les paramètres en utilisant l'algorithme EM

Hypothèse NMAR : *Not Missing At Random*

- Les variables ayant des observations manquantes dépendent de variables inconnues non observées
- ⇒ Identifier et ajouter de nouvelles variables pertinentes dans le modèle
- ⇒ Retour à l'hypothèse MAR

Apprentissage des LPC : Données incomplètes

Algorithme Expectation-Maximisation (Dempster, Laird et Rubin 1977)

Principes de l'algorithme EM

- Classe d'algorithmes d'optimisation itératifs
- Décomposition d'un problème d'optimisation complexe en deux sous problèmes d'optimisation alternés plus simples

Principale application

- Calculer les estimations des paramètres d'un modèle probabiliste par la méthode du maximum de vraisemblance en présence de données incomplètes

Propriétés

- Méthode d'optimisation locale
- ⇒ La convergence vers l'optimum global n'est pas garantie
- ⇒ La qualité de la solution calculée dépend de l'initialisation de l'algorithme

Apprentissage des LPC : Données incomplètes

Algorithme Expectation-Maximisation (Dempster, Laird et Rubin 1977)

Principes de l'algorithme EM

- Classe d'algorithmes d'optimisation itératifs
- Décomposition d'un problème d'optimisation complexe en deux sous problèmes d'optimisation alternés plus simples

Principale application

- Calculer les estimations des paramètres d'un modèle probabiliste par la méthode du maximum de vraisemblance en présence de données incomplètes

Propriétés

- Méthode d'optimisation locale
- ⇒ La convergence vers l'optimum global n'est pas garantie
- ⇒ La qualité de la solution calculée dépend de l'initialisation de l'algorithme

Apprentissage des LPC : Données incomplètes

Algorithme Expectation-Maximisation (Dempster, Laird et Rubin 1977)

Principes de l'algorithme EM

- Classe d'algorithmes d'optimisation itératifs
- Décomposition d'un problème d'optimisation complexe en deux sous problèmes d'optimisation alternés plus simples

Principale application

- Calculer les estimations des paramètres d'un modèle probabiliste par la méthode du maximum de vraisemblance en présence de données incomplètes

Propriétés

- Méthode d'optimisation locale
- ⇒ La convergence vers l'optimum global n'est pas garantie
- ⇒ La qualité de la solution calculée dépend de l'initialisation de l'algorithme

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Contexte

Contexte

- Données disponibles $\mathcal{D} = \mathcal{D}_C \cup \mathcal{D}_I$:
 - \mathcal{D}_C : Observations complètement observées
 - \mathcal{D}_I : Observations partiellement observées
- Modélisation : \mathcal{D} = réalisations i.i.d. de la suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$ représenté par un RB \mathcal{M} de structure supposée connue

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	?	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
?	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	?

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Contexte

Contexte

- Données disponibles $\mathcal{D} = \mathcal{D}_C \cup \mathcal{D}_I$:
 - \mathcal{D}_C : Observations complètement observées
 - \mathcal{D}_I : Observations partiellement observées
- Modélisation : \mathcal{D} = réalisations i.i.d. de la suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$ représenté par un RB \mathcal{M} de structure supposée connue

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	?	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
?	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	?

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Contexte

Contexte

- Données disponibles $\mathcal{D} = \mathcal{D}_c \cup \mathcal{D}_i$:
 - \mathcal{D}_c : Observations complètement observées
 - \mathcal{D}_i : Observations partiellement observées
- Modélisation : \mathcal{D} = réalisations i.i.d. de la suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$ représenté par un RB \mathcal{M} de structure supposée connue

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	?	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
?	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	?

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Contexte


Contexte

- Données disponibles $\mathcal{D} = \mathcal{D}_C \cup \mathcal{D}_I$:
 - \mathcal{D}_C : Observations complètement observées
 - \mathcal{D}_I : Observations partiellement observées
- Modélisation : \mathcal{D} = réalisations i.i.d. de la suite de v.a. $\mathbf{X} = (X_1, \dots, X_D)$ représenté par un RB \mathcal{M} de structure supposée connue

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	?	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
?	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	?

P(Age Vente)			
	Age		
Vente	[18,25]	[26,59]	60+
échec			
succès			

P(Épargne Vente)		
	Épargne	
Vente	non	oui
échec		
succès		



P(Vente)	
Vente	
échec	succès

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Données d'entrée


Données \mathcal{D}

A : Classe âge	E : Épargne	V : Vente livret A
[26,59]	non	échec
[18,25]	non	échec
[26,59]	non	échec
[26,59]	?	échec
60+	oui	succès
60+	oui	échec
[18,25]	oui	succès
60+	non	échec
?	non	échec
[26,59]	non	succès
[18,25]	non	succès
[26,59]	oui	succès
[26,59]	oui	échec
[26,59]	non	?

Modèle \mathcal{M}

P(Âge Vente)			
	Âge		
Vente	[18,25]	[26,59]	60+
échec			
succès			

P(Épargne Vente)		
	Épargne	
Vente	non	oui
échec		
succès		



P(Vente)	
Vente	
échec	succès

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Données d'entrée


Données \mathcal{D}

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	?	?	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
?	?	?	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	?	?

Modèle \mathcal{M}

P(Âge Vente)			
	Âge		
Vente	[18,25]	[26,59]	60+
échec			
succès			

P(Épargne Vente)		
	Épargne	
Vente	non	oui
échec		
succès		



Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Initialisation


Données $\mathcal{D}^{(0)}$

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	?	?	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
?	?	?	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	?	?

Modèle $\mathcal{M}^{(0)}$

P(Âge Vente)			
	Âge		
Vente	[18,25]	[26,59]	60+
échec	1/3	1/3	1/3
succès	1/3	1/3	1/3

P(Épargne Vente)		
	Épargne	
Vente	non	oui
échec	1/2	1/2
succès	1/2	1/2



P(Vente)	
Vente	
échec	succès
1/2	1/2

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Intération 1 - Étape E


Données $\mathcal{D}^{(1)}$

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	1/2	1/2	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
1/3	1/3	1/3	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	1/2	1/2

Modèle $\mathcal{M}^{(0)}$

P(Âge Vente)			
	Âge		
Vente	[18,25]	[26,59]	60+
échec	1/3	1/3	1/3
succès	1/3	1/3	1/3

P(Épargne Vente)		
	Épargne	
Vente	non	oui
échec	1/2	1/2
succès	1/2	1/2



P(Vente)	
Vente	
échec	succès
1/2	1/2

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Itération 1 - Étape M


Données $\mathcal{D}^{(1)}$

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	1/2	1/2	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
1/3	1/3	1/3	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	1/2	1/2

Modèle $\mathcal{M}^{(1)}$

$P^{(1)}(\text{Âge} \text{Vente})$			
	Âge		
Vente	[18,25]	[26,59]	60+
échec	7/24	10/24	7/24
succès	2/5	2/5	1/5

$P^{(1)}(\text{Épargne} \text{Vente})$		
	Épargne	
Vente	non	oui
échec	5,5/8	2,5/8
succès	2/5	3/5



$P^{(1)}(\text{Vente})$	
Vente	
échec	succès
8,5/14	5,5/14

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Intération 2 - Étape E


Données $\mathcal{D}^{(2)}$

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	0,6875	0,3125	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
0,292	0,417	0,292	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	0,735	0,265

Modèle $\mathcal{M}^{(1)}$

$\Delta P^{(1)}(\text{Âge} \text{Vente})$			
	Âge		
Vente	[18,25]	[26,59]	60+
échec	0,292	0,417	0,292
succès	0,4	0,4	0,2

$\Delta P^{(1)}(\text{Épargne} \text{Vente})$		
	Épargne	
Vente	non	oui
échec	0,6875	0,3125
succès	0,4	0,6



Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Itération 2 - Étape M


Données $\mathcal{D}^{(2)}$

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	0,6875	0,3125	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
0,292	0,417	0,292	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	0,735	0,265

Modèle $\mathcal{M}^{(2)}$

$\Delta P^{(2)}(\text{Âge} \text{Vente})$			
	Âge		
Vente	[18,25]	[26,59]	60+
échec	0,286	0,428	0,286
succès	0,4	0,4	0,2

$\Delta P^{(2)}(\text{Épargne} \text{Vente})$		
	Épargne	
Vente	non	oui
échec	0,711	0,289
succès	0,4	0,6



$\Delta P^{(2)}(\text{Vente})$	
Vente	
échec	succès
0,624	0,376

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Illustration

Algorithme EM : Intération 3 - Étape E


Données $\mathcal{D}^{(3)}$

A : Classe âge			E : Épargne		V : Vente livret A	
[18,25]	[26,59]	60+	non	oui	échec	succès
0	1	0	1	0	1	0
1	0	0	1	0	1	0
1	0	0	1	0	1	0
0	1	0	0,711	0,289	1	0
0	0	1	0	1	0	1
0	0	1	0	1	1	0
1	0	0	0	1	0	1
0	0	1	1	0	1	0
0,286	0,428	0,286	1	0	1	0
0	1	0	1	0	0	1
1	0	0	1	0	0	1
0	1	0	0	1	0	1
0	1	0	0	1	1	0
0	1	0	1	0	0,759	0,241

Modèle $\mathcal{M}^{(2)}$

$\Delta P^{(2)}(\text{Âge} \text{Vente})$			
	Âge		
Vente	[18,25]	[26,59]	60+
échec	0,286	0,428	0,286
succès	0,4	0,4	0,2

$\Delta P^{(2)}(\text{Épargne} \text{Vente})$		
	Épargne	
Vente	non	oui
échec	0,711	0,289
succès	0,4	0,6



$\Delta P^{(2)}(\text{Vente})$	
Vente	
échec	succès
0,624	0,376

Apprentissage des LPC : Données incomplètes

Algorithme EM dans les RB - Méthode

Algorithme EM dans les RB (structure connue)

- Initialisation du modèle RB $\mathcal{M}^{(0)}$ caractérisé par ses LPC
- **Étape E** : Estimer la loi des données manquantes à partir du RB courant, noté $\mathcal{M}^{(t)}$
 - Pour chaque donnée incomplète $\mathbf{x} = (\mathbf{x}_{\text{obs}}, \mathbf{x}_{\text{mqt}}) \in \mathcal{D}_I$
 - Calculer la distribution de ses variables manquantes \mathbf{X}_{mqt} conditionnellement à ses variables observées \mathbf{X}_{obs}
 - ⇒ Calculer $P(\mathbf{X}_{\text{obs}} | \mathbf{X}_{\text{mqt}})$ en utilisant un algorithme d'inférence dans $\mathcal{M}^{(t)}$
 - ⇒ "Nouvelles" données courante $\mathcal{D}^{(t+1)} = \mathcal{D}_C \cup \mathcal{D}_I^{(t+1)}$ complétées par les distributions des variables manquantes
- **Étape M** : Estimer les LPC du modèle $\mathcal{M}^{(t+1)}$ à partir des données complétées $\mathcal{D}^{(t)}$
 - ⇒ Utilisation de la méthode du maximum de vraisemblance
- Répéter les étapes E et M tant que $\mathcal{M}^{(t)}$ et $\mathcal{M}^{(t+1)}$ sont significativement différents

Références



Dempster, A., N. Laird et D. B. Rubin (1977). "Maximum Likelihood from Incomplete Data Via the EM Algorithm". In : *Journal of the Royal Statistical Society B* 39, p. 1-38.



Fisher, R. A. (1922). "On the Mathematical Foundations of Theoretical Statistics". In : *Philosophical Transactions of the Royal Society of London. Series A, Containing Papers of a Mathematical or Physical Character* 222, p. 309-368.



Rubin, D. B. (déc. 1976). "Inference and missing data". In : *Biometrika* 63.3, p. 581-592.